

3. [Entrega-AD-EC-3] Estimación de búsquedas locales

Grupo1: Naroa Iparraguirre, Xiomara Cáceres y Iraida Abad

19 de enero de 2025

Este documento describe el código para resolver el Problema de Asignación Cuadrática (QAP) utilizando varias técnicas de búsqueda local, como “Best First” y “Greedy”, así como métodos para estimar óptimos locales. Se explica cada función del código según su propósito y funcionalidad.

1. Teoria estimación de óptimos locales

1.1. Chao 1984, Chao & Lee 1992, Chao & Bunge 2002

1. Elegir m soluciones al azar
2. Aplicar algoritmo de búsqueda local sobre las soluciones
3. Contar los óptimos locales r
4. Calcular el índice r / m

El índice intenta estimar el número de óptimos locales en el problema. Si todos los óptimos locales son diferentes, entonces el índice r / m será igual a la proporción del espacio de soluciones que está cubierto por los óptimos locales encontrados. Esto implica que al aumentar m , la estimación será más precisa y el valor del índice tenderá a estabilizarse. En cambio, si algunos óptimos locales son iguales, el índice subestima la cantidad total de óptimos distintos.

1.2. Schnabel Census Procedure

1. Elegir m soluciones al azar
2. Comprobar cada solución y verificar si es óptimo local
3. Contar los óptimos locales r
4. Calcular el índice r / m

El porcentaje real de óptimos locales se puede aproximar en ambos casos de manera eficiente cuando el número de muestras m es suficientemente grande. Esto se debe a que a medida que m tiende a infinito ($\lim_{m \rightarrow \infty}$), el valor de r/m se estabiliza, proporcionando una representación fiable del porcentaje de óptimos locales en el espacio de soluciones. Para aplicaciones prácticas, es importante equilibrar la cantidad de soluciones probadas (m) con los recursos computacionales disponibles.

2. Funciones Auxiliares

2.1. `read_instance_QAP(filepath)`

Propósito: Cargar una instancia del problema QAP desde un archivo y devolver los datos correspondientes.

Parámetros:

- `filepath`: Ruta al archivo que contiene la instancia.

Salida: Una tupla (`size`, `D`, `H`).

- `size`: Tamaño del problema (número de instalaciones/lugares).
- `D`: Matriz de distancias entre lugares.
- `H`: Matriz de flujos entre instalaciones.

Descripción:

1. Abre el archivo y lee el tamaño del problema.
2. Llena las matrices `D` y `H` con los datos del archivo.
3. Devuelve los datos procesados.

2.2. `objective_function_QAP(solution, instance)`

Propósito: Calcular el valor de la función objetivo para una solución dada.

Parámetros:

- `solution`: Vector que representa una asignación de instalaciones a lugares.
- `instance`: Tupla (`size`, `D`, `H`) que representa la instancia del problema.

Salida: El valor de la función objetivo calculado.

Descripción:

1. Recorre todas las combinaciones de instalaciones.
2. Suma los productos de las distancias (matriz `D`) y los flujos (matriz `H`) correspondientes a la solución.

3. Funciones de Generación de Vecinos

3.1. ExchangeVector(V, i, j)

Propósito: Intercambiar dos elementos en un vector.

Parámetros:

- V: Vector de entrada.
- i, j: Índices de los elementos a intercambiar.

Salida: El vector modificado con los elementos intercambiados.

3.2. calcularVecinosExchange(N, vectorIni)

Propósito: Generar todos los vecinos posibles de una solución mediante intercambios de elementos.

Parámetros:

- N: Tamaño del vector.
- vectorIni: Solución inicial.

Salida: Una lista con todos los vectores vecinos generados.

Descripción:

1. Recorre todas las combinaciones posibles de pares de índices.
2. Genera un nuevo vector para cada par intercambiado.
3. Devuelve la lista de vecinos.

4. Algoritmo Best First

4.1. calcularMejorVecinosExchangeBestFirst(instance, N, vectorIni, valorIni)

Propósito: Encontrar el mejor vecino de una solución inicial utilizando el enfoque “Best First”.

Parámetros:

- instance: Instancia del problema.
- N: Tamaño del problema.
- vectorIni: Solución inicial.
- valorIni: Valor de la función objetivo para la solución inicial.

Salida: Una tupla (optimo_global_encontrado, valor_solucion_local, solucion_local).

Descripción:

1. Genera los vecinos de la solución inicial.
2. Calcula el valor de la función objetivo para cada vecino.
3. Devuelve el vecino con el menor valor de la función objetivo.

4.2. `best_first_solution(possible_solution, size, i_max, instance)`

Propósito: Iterar el proceso “Best First” hasta alcanzar un óptimo local o superar el número máximo de iteraciones.

Parámetros:

- `possible_solution`: Solución inicial.
- `size`: Tamaño del problema.
- `i_max`: Número máximo de iteraciones.
- `instance`: Instancia del problema.

Salida: Una tupla con información sobre la última iteración.

Descripción:

1. Actualiza la solución inicial iterativamente usando el mejor vecino.
2. Verifica si se alcanza un óptimo local.
3. Devuelve la solución final y su valor.

5. Algoritmo Greedy

5.1. `calcularMejorVecinosExchangeGreedy(instance, N, vectorIni, valorIni)`

Propósito: Seleccionar vecinos de forma aleatoria y encontrar una solución mejorada.

Parámetros: Igual a `calcularMejorVecinosExchangeBestFirst`.

Diferencia Principal: Genera vecinos aleatorios en lugar de generar todos los vecinos.

5.2. `greedy_search_solution(possible_solution, size, i_max, instance)`

Propósito: Aplicar el enfoque Greedy iterativamente.

Parámetros: Igual a `best_first_solution`.

Salida: Igual a `best_first_solution`.

6. Estimación de Óptimos Locales

6.1. `ejecutar_Chao_1984_Chao_and_Lee_1992_Chao_and_Bunge_2002(i_max, m, instance, size)`

Propósito: Aplicar técnicas basadas en publicaciones académicas para estimar el número de óptimos locales.

Parámetros:

- `i_max`: Número máximo de iteraciones.
- `m`: Número de soluciones iniciales aleatorias.
- `instance`: Instancia del problema.
- `size`: Tamaño del problema.

Descripción:

1. Genera `m` soluciones iniciales.
2. Aplica el algoritmo “Best First” a cada una.
3. Cuenta y calcula el índice de óptimos locales encontrados.

6.2. `ejecutar_schnabel_census_procedure(i_max, m, instance, size)`

Propósito: Aplicar la técnica Schnabel para estimar óptimos locales usando el algoritmo Greedy.

Parámetros: Igual a `ejecutar_Chao_1984_Chao_and_Lee_1992_Chao_and_Bunge_2002`.

Descripción:

1. Genera `m` soluciones iniciales.
2. Aplica el algoritmo “Greedy” a cada una.
3. Cuenta y calcula el índice de óptimos locales encontrados.

7. Ejecución Principal

7.1. Bloque Main

1. Carga las instancias del problema desde archivos.
2. Ejecuta los algoritmos “Best First” y “Greedy” en cada instancia.
3. Aplica las técnicas de estimación de óptimos locales.
4. Imprime los resultados.

8. Pregunta:

¿Cuál es el valor óptimo de m para que el ratio r/m sea capaz de estimar de manera eficiente el número de óptimos locales?

La elección del valor óptimo de m para que el ratio r/m sea capaz de estimar de manera eficiente el número de óptimos locales depende de la naturaleza del problema y del tamaño del espacio de soluciones. Generalmente, el valor de m debe ser suficientemente grande para capturar una muestra representativa del espacio de soluciones. Esto asegura que:

- Se encuentren una cantidad significativa de óptimos locales r , proporcionando un cálculo más preciso del ratio r/m .
- La variabilidad en las estimaciones disminuya a medida que m aumenta.

En términos prácticos, el valor óptimo de m puede determinarse experimentalmente mediante iteraciones sucesivas, observando la estabilización del ratio r/m . Idealmente, m debería satisfacer la condición:

$$m \geq k \cdot n$$

donde n es el tamaño del problema (por ejemplo, el número de elementos en el problema de asignación cuadrática) y k es un factor de escala basado en el número esperado de óptimos locales.

En el límite, cuando $m \rightarrow \infty$, el ratio r/m convergerá al valor verdadero del porcentaje de óptimos locales en el espacio de soluciones:

$$\lim_{m \rightarrow \infty} \frac{r}{m} = \text{porcentaje_real_de_óptimos_locales}$$